

# 量化模型总结

– Created: April 24, 2024

– Last Modified: June 8, 2024

**Abstract:** 介绍我了解的量化交易中使用的时序模型、因子模型和机器学习模型。

## 1 什么是模型

模型是用来表示一个关系的东西，关系不一定是因果关系，但我们仍用自变量 $\mathbf{x}$ 和因变量 $y$ 这样的名字。所以模型就可以写为

$$f(\mathbf{x}) : \mathbf{x} \mapsto y \quad (1)$$

如果我们对资产收益率 $r$ 建模，那么 $y = r$ ， $\mathbf{x}$ 表示影响资产收益率的因素。

通过选取不同的 $f$ 的形式，能得到下面几种模型：时间序列模型、因子模型、机器学习模型。

### 1.1 时间序列模型

时间序列模型的 $\mathbf{x}$ 选择收益率的历史序列  $\mathbf{x} = [r_{t-1}, \dots, r_{t-K}]$ ,  $y = r_t$ 。这种模型的假设是收益率受一些未知随机因素影响（MA），并且受自己历史值的影响（AR）。最常用的时间序列模型是ARIMA模型。中间的I是通过差分把不平稳的序列变平稳。

#### 1.1.1 ARIMA模型

对一个时间序列进行ARIMA (p,d,q) 模型建模步骤如下：

1. 序列的平稳性检验。如果不平稳，需要利用一次或多次差分将其转化为平稳序列。如果怎么差分都不平稳，放弃ARIMA模型。
2. 白噪声检验。如果序列是白噪声，可以终止对该序列的分析。啥模型都不管用。
3. 对于平稳非白噪声序列，可以用ARIMA (p,d,q) 模型(加入I主要是将非平稳序列转换为平稳序列，d是差分阶数)。
4. 模型定阶，把p,d,q算出来。
5. 参数估计，包括系数检验和拟合优度检验
6. 残差序列的白噪声检验。
7. 预测。

参考:

1. ARIMA模型建模的具体过程
2. 使用python的statsmodels模块拟合ARIMA模型

### 1.1.2 ARCH系列模型

ARIMA模型主要在刻画收益率的均值，它假设扰动项为白噪声序列，实际上收益率的方差存在聚集效应。条件异方差模型就是在均值建模的基础上，再增加一个收益率的方差随时间变化的模型。这可以更精确刻画收益率的条件分布。

## 1.2 因子模型

因子模型假设不同资产的收益率由共同的因子影响，并将这些共同因子的收益率做为自变量。

### 1.2.1 CAPM

最简单的因子模型是CAPM模型，它只有一个市场因子，其收益率记为 $r_M$ ，则CAPM单因子模型可写为

$$r_t = \beta r_{M,t} + \epsilon_t$$

为简单起见，上面的 $r_t$ 和 $r_{M,t}$ 分别表示减去无风险利率 $r_f$ 之后的值，表示超额收益 risk premium，下标 $t$ 表示时间，资产下标 $i$ 省略，如果不特别说明， $r_t$ 表示某个资产在 $t$ 时刻的超额收益。

收益率使用百分比收益率，主要原因是百分比收益率可以做加权求和，这样因子模型就能用到资产组合上来。

当我们对式子左侧求期望，就可以得到资产的预期收益率，同样，对于 $N$ 个资产组成的资产组合，我们可以求他们的协方差。由预期收益率和协方差矩阵，就可以通过mean-variance optimisation来求资产组合的最优权重。

### 1.2.2 Fama-French三因子模型

再复杂点是Fama和French于1993年提出来的三因子模型。

除了市场因子之外，Fama-French三因子模型还引入了大小Size和价值Value两个因子。Size由公司的BM book to market ratio反映，价值用市值market value来反映，BM和MV明显是不独立的，为了保证因子的独立，在构造因子时使用了多重排序法，也就出来的经典的SMB和HML。

但是SMB和HML并不是因子收益率，所以要通过Fama-McBeth回归得到以因子收益率为自变量的回归方程。

$$r_t = \beta_M r_{M,t} + \beta_{SMB} r_{SMB,t} + \beta_{HML} r_{HML,t} + \epsilon_t$$

### 1.2.3 Barra 风险模型

与Fama-French模型用来解释资产收益率不同，风险模型比如MSCI Barra 的目标是更准确地估计资产的协方差矩阵。虽然收益模型和风险模型可以用同样的因子，但貌似预期收益和风险确实受不同因子的影响。Barra的CNE5模型有1个国家因子，P个行业因子，Q个风格因子。具体写为

$$r_t = 1\lambda_{C,t} + \sum_i^P \beta_{I_i} \lambda_{I_i,t} + \sum_i^Q \beta_{S_i} \lambda_{S_i,t} + \epsilon_t$$

式中 $\lambda_{C,t}$ 是t时刻国家因子的收益率，经推导，国家因子收益率基本等于市场组合的超额收益，即前面模型中的市场因子。但是CNE5强制所有资产在国家因子上的暴露为1，这是不同的点。另外Barra模型的因子收益率计算方法和Fama-MacBeth方法有点区别，它直接使用公司特征作为因子暴露的原始值，而不是时序回归系数。

Barra CNE5S, CNE6模型的数据来源有

1. 股票和指数的日行情数据，包含turnover rate, amount, return, close, circ mv, total mv, index return
2. 三大财务报表(季度数据): 利润表income, 资产负债表balancesheet、现金流表cashflow
3. 公司主要财务分析指标新会计准则(季度数据)，根据报告期公布的财务科目数据衍生而来的指标，tushare 叫fina indicator, akshare里没找到，不清楚是不是财报必须的
4. 一级行业数据，如果某支股票换行业的话，是否要考虑？
5. 分析师预测数据，有可能来自wind万得，无法获取。

Barra因子原始值的计算，核心是数据频率的转换，尤其把季频数据转为日或者月频时，要考虑是使用上一年的数据，还是上一季度的数据，比如Market leverage MLEV因子中的PE和LD在CNE5S中使用的是most recent quarter, 在CNE6中使用的是上一财年last fiscal year的数据。有些要用ttm值的，还需要计算ttm。

数据的频率转换完成之后，按公式计算即可。

如果使用python的pandas，DataFrame的格式为，每行为一天，每列为一支股票，天为索引，如下所示

	600221.SH	601006.SH	601288.SH	603127.SH	603206.SH
trade_date					
2022-04-29	0.000000	-0.020588	0.000000	0.085789	NaN
2022-05-05	-0.033520	-0.010511	0.006536	-0.035183	NaN
2022-05-06	-0.028902	-0.013657	-0.009740	-0.029902	0.439780
2022-05-09	0.005952	0.012308	0.006557	0.003652	0.099904
2022-05-10	-0.005917	-0.009119	0.006515	-0.003959	0.099957

具体的计算使用的是github上开源的代码 ShiliangZhang-nku Barra CNE6

我的数据来自数据库，数据采集部分的代码修改自phonegapX alphasickle.

需要做一个适配层来适配这两份代码，最终数据采集和因子生成两部分的代码结构如图1。

#### 1.2.4 因子投资组合 factor portfolio

在使用OLS求解因子模型时，不管是收益模型和风险模型，中间过程存在一个权重矩阵，使得按这个权重对资产配置时，各个组合的收益率互不相交，这些组合被称为因子组合。使用因子组合能够构造特定暴露的资产组合。

#### 1.2.5 投资组合优化

有了收益模型和风险模型之后，就可以结合一定的目标函数（比如Markovitz均值方差优化、risk parity等）来求取最优的投资组合。如果风险和收益模型使用不同的因子，一个潜在的问题是优化器会倾向风险模型覆盖不到的那些因子的权重，需要在优化时做特殊考虑。

### 1.3 机器学习模型

这个非常直接，就是找各种特征  $\mathbf{x}$ ，之后通过数据来训练模型，使其逼近收益率的预测公式  $r_{t+n} = f(\mathbf{x}_t)$

## 2 利率模型

### 2.1 国债收益率

国内市场债券的收益率曲线和估值有“中债估值”和“中证估值”。中证估值发布的曲线有债券实时收益率曲线和债券收盘收益率曲线。中债估计发布的是中国国债收益率曲线，应该对应中证的收盘收益率曲线。

这些曲线的数据源都来自一级和二级市场的报价。实时曲线为到期收益率曲线，包括报买入、报卖出和均值曲线等3条曲线。交易日每1小时更新一次。

收盘曲线以当日对应债券样本的双边报价和成交数据为样本，利用线性回归模型计算(不清楚模型的输入和输出分别是啥)得到收盘到期收益率曲线，利用收盘到期收益率曲线推导出对应的即期和远期利率曲线。

即期利率可以用票息剥离法(bootstrap method)从到期收益率来计算。远期收益率一般记作  $y(n, k)$ ，表示  $n$  年后， $k$  年期债券的即期收益率。远期收益率可以通过期收益率曲线迭代求出来。中债的国债到期收益率曲线如图2所示，即期曲线的趋势基本一致，有两点观察：远期收益率高于近期收益率，是正常的期限结构；近10年以来，收益率呈下降趋势（为什么？）。

这个曲线有什么用呢？我自己的感觉：

1. 判断二级市场一个债券价格是不是合理，比如23国债27（019730）期限是2年期，coupon rate 2.33%，当前价格是100.952，可以求得YTM是1.6%，和收益率曲线是一致的。如

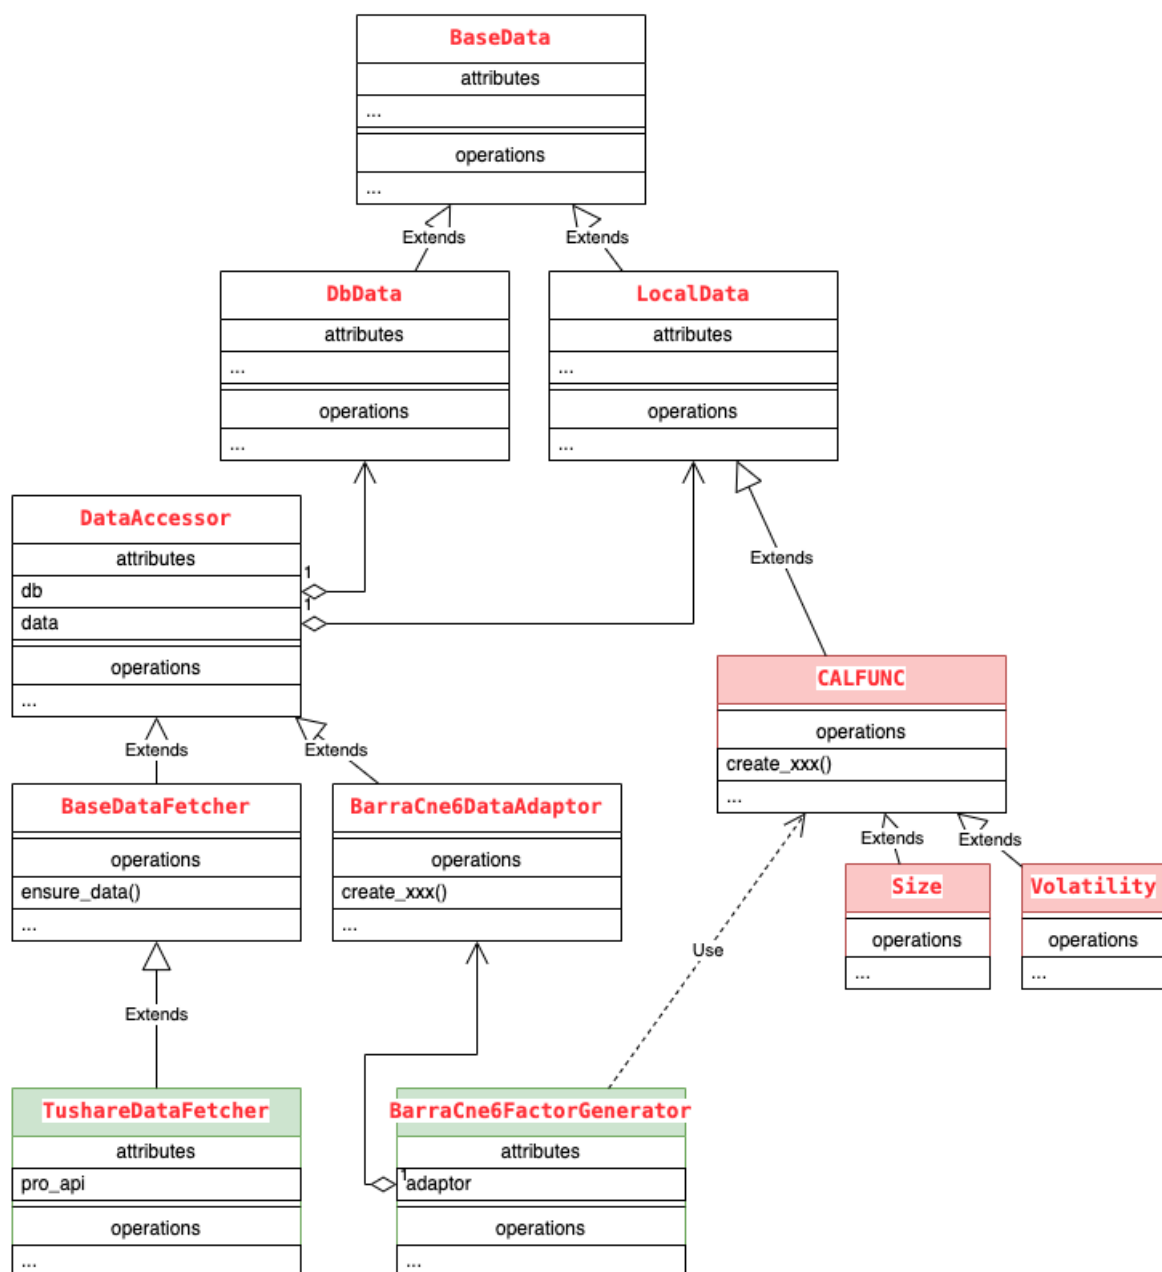


Figure 1: Barra 数据采集与因子计算架构




Figure 2: 中债国债收益率曲线(到期)

果有偏离收益率曲线比较大的债券，是不是就是买卖的机会呢？

2. 还有一种策略叫骑乘策略，或者骑乘收益率曲线（Riding the yield curve），即根据债券剩余期限变短其收益率逐渐下滑（即债券价格上升）的特点，买入年期即将退化的债券品种，等待其收益率出现快速下滑时卖出。采用骑乘收益率曲线的方式必须满足两个条件：1、收益率曲线向上倾斜，即长期债券的收益率较短期债券高。2、投资者确信收益率曲线将继续保持上升的态势，而不会发生变化。实际操作时还不知道该怎么操作。

债券市场中还有一种常见投资策略叫做久期策略，基于对未来利率走势的预测来主动调整组合的久期。“利率涨，短久期；利率降，长久期”。虽然债券收益率浮动很少，但债券投资的规模一般都很大，而且经常会利用杠杆，所以微小的收益率差异都能带来巨大收益。久期策略的关键在于能够准确预测市场利率的变化方向及幅度，也被称作利率预测法。利率预测法的理论基础应该是 Antti Ilmanen(1995)的 Understanding the Yield Curve，其中提出了一个债券收益分解模型，将债券收益分解为两大部分：利率曲线不变带来的收益和利率曲线变动带来的收益。

### 3 未完成的模型

1. 时间序列模型ARIMA
2. ARCH模型
3. MSCI CNE5 模型，需要看在风险因子上的暴露
4. Fama-French 5因子模型
5. Hou-Xue-Zhang四因子模型